不同的机器上,具体多少台机器由面试官规定或者由更多的限制来决定。对每一台机器来说,如果分到的数据量依然很大,比如,内存不够或其他问题,可以再用哈希函数把每台机器的分流文件拆成更小的文件处理。处理每一个小文件的时候,哈希表统计每种词及其词频,哈希表记录建立完成后,再遍历哈希表,遍历哈希表的过程中使用大小为 100 的小根堆来选出每一个小文件的 top 100 (整体未排序的 top 100)。每一个小文件都有自己词频的小根堆(整体未排序的 top 100),将小根堆里的词按照词频排序,就得到了每个小文件的排序后 top 100。然后把各个小文件排序后的 top 100 进行外排序或者继续利用小根堆,就可以选出每台机器上的 top 100。不同机器之间的 top100 再进行外排序或者继续利用小根堆,最终求出整个百亿数据量中的 top 100。对于 top K 的问题,除哈希函数分流和用哈希表做词频统计之外,还经常用堆结构和外排序的手段进行处理。

40 亿个非负整数中找到出现两次的数和所有数的中位数

【题目】

32 位无符号整数的范围是 0~4294967295, 现在有 40 亿个无符号整数,可以使用最多 1GB 的内存,找出所有出现了两次的数。

【补充题目】

可以使用最多 10MB 的内存,怎么找到这 40 亿个整数的中位数?

【难度】

尉★★☆☆

【解答】

对于原问题,可以用 bit map 的方式来表示数出现的情况。具体地说,是申请一个长度为 4294967295×2 的 bit 类型的数组 bitArr,用 2 个位置表示一个数出现的词频,1B 占用 8 个 bit,所以长度为 4294967295×2 的 bit 类型的数组占用 1GB 空间。怎么使用这个 bitArr 数组呢?遍历这 40 亿个无符号数,如果初次遇到 num,就把 bitArr[num*2 + 1]和 bitArr[num*2]设置为 01,如果第二次遇到 num,就把 bitArr[num*2+1]和 bitArr[num*2]设置为 10,如果第三次遇到 num,就把 bitArr[num*2+1]和 bitArr[num*2]设置为 11。以后再遇

到 num,发现此时 bitArr[num*2+1]和 bitArr[num*2]已经被设置为 11,就不再做任何设置。 遍历完成后,再依次遍历 bitArr,如果发现 bitArr[i*2+1]和 bitArr[i*2]设置为 10,那么 i 就是出现了两次的数。

对于补充问题,用分区间的方式处理,长度为 2MB 的无符号整型数组占用的空间为 8MB,所以将区间的数量定为 4294967295/2M,向上取整为 2148 个区间。第 0 区间为 $0\sim2M-1$,第 1 区间为 $2M\sim4M-1$,第 i 区间为 $2M\times i\sim2M\times(i+1)-1\cdots$

申请一个长度为 2148 的无符号整型数组 arr[0..2147],arr[i]表示第 *i* 区间有多少个数。arr 必然小于 10MB。然后遍历 40 亿个数,如果遍历到当前数为 num,先看 num 落在哪个区间上(num/2M),然后将对应的进行 arr[num/2M]++操作。这样遍历下来,就得到了每一个区间的数的出现状况,通过累加每个区间的出现次数,就可以找到 40 亿个数的中位数(也就是第 20 亿个数)到底落在哪个区间上。比如,0~K-1 区间上数的个数为 19.998 亿,但是发现当加上第 *K* 个区间上数的个数之后就超过了 20 亿,那么可以知道第 20 亿个数是第 *K* 区间上的数,并且可以知道第 20 亿个数是第 *K* 区间上的第 0.002 亿个数。

接下来申请一个长度为 2MB 的无符号整型数组 countArr[0..2M-1],占用空间 8MB。然后再遍历 40 亿个数,此时只关心处在第 K 区间的数记为 numi,其他的数省略,然后将 countArr[numi-K*2M]++,也就是只对第 K 区间的数做频率统计。这次遍历完 40 亿个数之后,就得到了第 K 区间的词频统计结果 countArr,最后只在第 K 区间上找到第 0.002 亿个数即可。

一致性哈希算法的基本原理

【题目】

工程师常使用服务器集群来设计和实现数据缓存,以下是常见的策略:

- 1. 无论是添加、查询还是删除数据,都先将数据的 id 通过哈希函数转换成一个哈希值,记为 key。
- 2. 如果目前机器有N台,则计算 key%N的值,这个值就是该数据所属的机器编号,无论是添加、删除还是查询操作,都只在这台机器上进行。

请分析这种缓存策略可能带来的问题,并提出改进的方案。